# Summer Delta Attention v5-Gated と Kimi Delta Attention の比較実験

合成連想記憶における検索精度と記憶容量のトレードオフ

**summer**

研究論文草稿・2026 年 10 月 23 日・査読前プレプリント

**Abstract**

本研究は、忘却なし Delta Rule の高速状態にインデックス付き Key–Value（KV）検索を付加した *Summer Delta Attention v5-Gated*（SDA-5）と、*Kimi Delta Attention*（KDA）の再帰状態更新を比較する。NumPy による合成連想記憶実験を行い、Key 次元 32、Value 次元 16、Query 数 128、独立なテスト 16 シード、記憶系列長 128〜2,048 で評価した。512 件を書き込んだ後にノイズなしで元 Value を検索する条件では、KV の 50% を保存する SDA-5 の平均二乗誤差（MSE）は $0.4721 \pm 0.0099$（平均値 ± 標準誤差）、KDA 型のチャネル別ゲート付き再帰更新は $0.9336 \pm 0.0098$ であった。一方、SDA-5 の状態・KV 保存量は 100 KiB、KDA は 4 KiB であり、**記憶容量は 25 倍異なる**。単純な KV 直接検索は 96 KiB で MSE $0.4962 \pm 0.0101$ であった。KDA の原論文の更新式は用いたが、学習済みの入力依存ゲートや Kimi Linear 全体を再現したものではない。そのため、本結果は学習済み KDA に対する優位性を示さない。再現可能な計算手順、差分補正の代数的性質、実験条件、限界と公平な比較に必要な課題を報告する。

**キーワード：** Delta Rule、Kimi Delta Attention、連想記憶、インデックス検索、記憶効率、再現実験

## 1 はじめに

Full Attention は過去の KV へ内容に応じてアクセスできる一方、自己回帰推論の KV キャッシュ容量は文脈長に応じて増加する [1]。Delta Rule による Fast Weight は履歴を固定サイズの行列へ圧縮するが、新たな更新が以前の対応関係を壊す問題を持つ [2]。KDA は Gated DeltaNet の忘却ゲートをチャネル別に一般化し、高速なチャンク計算を設計した [4, 3]。実際の Kimi Linear は KDA だけではなく、Global な MLA も組み合わせる。したがって、KDA 単一再帰機構の実験と、学習済み Kimi Linear 全体の性能を混同してはならない。

SDA-5 は忘却ゲートを持たない Delta 状態に、件数上限のある明示的な KV 記憶を追加する。本稿では、SDA-5 が KDA 型の再帰更新と比べてどの程度正確にランダムな連想を再現できるか、およびその改善がどの程度の記憶容量を必要とするかを検証する。本稿の貢献は、(1) 両方式の比較用の明示的実装、(2) 開発用シードとテスト用シードの分離、(3) 容量を含む性能評価と KV 直接検索対照群、(4) 新規性・線形時間性に関する主張の境界の明確化である。

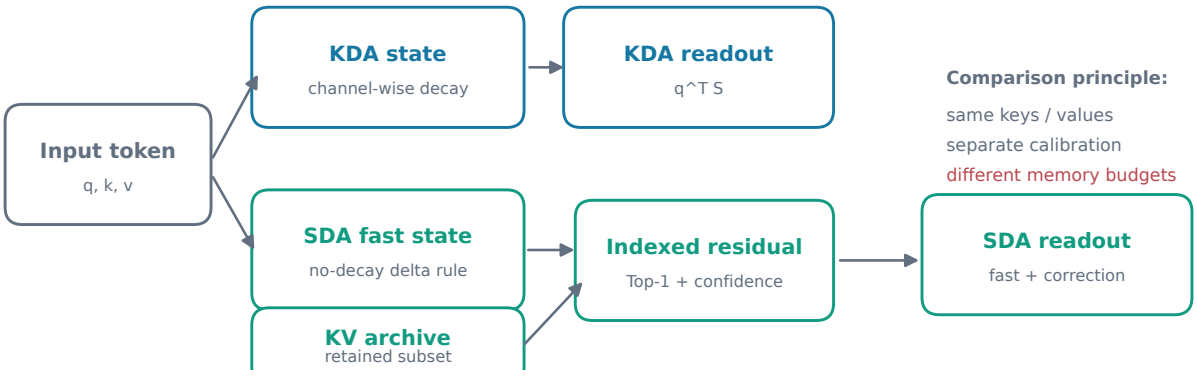



**Figure 1:** 比較アーキテクチャ。KDA はチャネル別忘却と Delta 更新による固定状態を使う。SDA-5 は忘却なし高速状態と選択保存 KV を併用する。図中の英語は実装上のモジュール名である。

# 2 比較するアルゴリズム

## 2.1 KDA の再帰更新と実装範囲

状態 $S_t \in \mathbb{R}^{d_k \times d_v}$、$q_t, k_t \in \mathbb{R}^{d_k}$、$v_t \in \mathbb{R}^{d_v}$ とする。KDA の基本再帰式は [4]

$$\bar{S}_t = \mathrm{Diag}(\boldsymbol{\alpha}_t) S_{t-1}, \tag{1}$$

$$S_t = \bar{S}_t + \beta_t k_t (v_t - \bar{S}_t^\top k_t)^\top, \tag{2}$$

$$o_t^{\mathrm{KDA}} = S_t^\top q_t \tag{3}$$

である。元の KDA では忘却係数 $\boldsymbol{\alpha}_t$ は学習可能かつ入力依存である。本稿ではネットワーク全体を学習せず、次のチャネル別ゲート付き *KDA* 近似モデルを使用する。

$$\alpha_{t,j} = \exp[-\ell c_j (1 + \eta \sqrt{d_k} |k_{t,j}|)], \quad c_j \in [0.5, 1.5]. \tag{4}$$

$\ell$、$\eta$、$\beta$ は独立した開発データで選択した。$\eta > 0$ なら入力依存のチャネル別忘却を表せるが、KDA の学習済み射影、短い畳み込み、複数 Head、出力ゲート、並列カーネル、MLA 混合構造は含まない。今回選ばれた正の忘却率の最良設定は $\eta = 0$ であり、最終的なゲートはチャネルによって異なるが時間的には一定である。忘却なし境界 $\ell = 0$ も参考として示す。

## 2.2 SDA-5 の残差補正と検索

高速状態 $F_t \in \mathbb{R}^{d_k \times d_v}$ を

$$e_t = v_t - F_{t-1}^\top k_t, \tag{5}$$

$$F_t = F_{t-1} + \beta_t k_t e_t^\top \tag{6}$$

で更新する。別に $B$ 件までの Key と Value をインデックス記憶 $\mathcal{M}_t$ に保存する。Query $q$ に最も似た Key を $k_{i^*}$ とし、類似度が閾値 $\tau$ 以上なら補正する。

$$i^* = \arg\max_{i \in \mathcal{M}_t} q^\top k_i, \tag{7}$$

$$g(q) = \mathbf{1}[q^\top k_{i^*} \geq \tau], \tag{8}$$

$$o^{\mathrm{SDA}}(q) = F_t^\top q + g(q)(v_{i^*} - F_t^\top k_{i^*}). \tag{9}$$

閾値未満なら高速状態の出力だけを使用する。KV 直接検索対照群は、閾値以上なら保存 Value、閾値未満ならゼロを返す。Value の真の分布が平均ゼロであるため、この対照群は本合成実験では強い設定である。保存対象は学習による選別ではなくランダム抽出であり、検索は ANN でなく厳密な全件走査である。

**命題 1** (単一検索の代数的等価性)**.** 検索した $(k_i, v_i)$ に対して式(9)は

$$o^{\mathrm{SDA}}(q) = F_t^\top (q - g k_i) + g v_i \tag{10}$$

と等価である。特に $q = k_i$、$g = 1$ なら $o^{\mathrm{SDA}} = v_i$ であり、$g = 1$ の誤差は $\|o^{\mathrm{SDA}}(q) - v_i\|_2 \leq \|F_t\|_2 \|q - k_i\|_2$ を満たす。

証明. 式(9)を展開し、$F_t^\top$ の項をまとめればよい。$g = 1$ として作用素ノルムの不等式を適用する。 □

したがって、SDA の完全一致復元は保存済みの *Value* を利用できることに大きく依存する。外部 KV 検索自体は既存研究に存在する [6]。本稿は新しい Attention ファミリーとしての独創性を実証したものではない。

## 2.3 計算量と記憶量

KDA、SDA 高速状態の更新はいずれもトークン当たり $O(d_k d_v)$ であり、固定状態として $O(d_k d_v)$ のメモリを使う。SDA はさらに $O(B(d_k + d_v))$ の KV 容量を必要とする。本稿の検索方法では Query 当たり $O(B d_k)$ の全件検索を行うため、$B \propto T$ の場合、長い系列での繰り返し検索は二次計算量になり得る。現段階で SDA 全体を固定メモリ型・線形時間型とは呼べない。

# 3 実験方法

系列長 $N \in \{128, 512, 2048\}$、Key 次元 $d_k = 32$、Value 次元 $d_v = 16$ とする。Key を正規分布から生成して L2 正規化し、Value は独立の標準正規分布から生成する。全 $N$ 件を書き込んだ後、元の Key を復元抽出して 128 Query を生成する。Query ノイズは

$$q = \frac{k_j + \sigma z/\sqrt{32}}{\|k_j + \sigma z/\sqrt{32}\|_2}, \qquad z \sim \mathcal{N}(0, I), \quad \sigma \in \{0, 0.4, 1\} \tag{11}$$

で与え、元の Value $v_j$ の再構成 MSE を測る。保存率 $\rho \in \{0.1, 0.25, 0.5, 1\}$ で、各試行のランダム順列から先頭 round($\rho N$) 件を KV として保存する。保存率を変えても順列は共通であり、保存集合は包含関係を持つ。

**学習・校正とテストの分離：**開発用は 8 シード（20250001〜20250008）、評価用は 16 シード（20261023〜20261038）。開発用では $N = 512$、$\sigma \in \{0, 0.4\}$ の平均 MSE を最小化する。KDA は $\beta \in \{0.05, 0.1, 0.2, 0.4, 0.7, 1\}$、$\ell \in \{0, 0.0005, 0.002, 0.008, 0.03\}$、$\eta \in \{0, 1\}$ を探索し、正の $\ell$ を持つ最良値も別に求める。SDA は同じ $\beta$ 候補と $\tau \in \{0.65, 0.75, 0.8, 0.85, 0.9\}$ を KV 保存率 50% で最適化する。結果、SDA は $\beta = 0.05, \tau = 0.75$、KDA 型の正の忘却ゲートは $\beta = 0.05, \ell = 0.0005, \eta = 0$ となった。従来の SDA 設定 $\beta = 1, \tau = 0.8$ も比較する。

Full Attention の参考値は softmax($32qK^\top$)$V$ とし、全件 KV を与える。Logit 倍率 32 は非常に鋭い検索に有利であり、同容量や学習済み Transformer の対等比較ではない。実装は CPU NumPy float64、容量は float64 配列における状態・KV の理論値であり、インデックス管理や一時バッファは含まない。ばらつきは 16 シードの平均値の標準誤差（SEM）で示す。

# 4 実験結果

## 4.1 主要結果

**Table 1:** $N = 512$、Query ノイズなし、SDA と直接 KV 検索は保存率 50%。テスト 16 シードの平均 MSE と状態・KV 容量。

| 方式 | MSE ± SEM | 容量 (KiB) |
|---|---|---|
| Full KV Softmax（鋭い検索・全 KV） | $\approx 0$ | 192 |
| KDA 型チャネル別ゲート近似 | $0.9336 \pm 0.0098$ | **4** |
| KDA の忘却なし境界 | $0.9301 \pm 0.0098$ | **4** |
| 忘却なし DeltaNet（校正済み） | $0.9301 \pm 0.0098$ | **4** |
| SDA-5 従来設定 | $0.9422 \pm 0.0221$ | 100 |
| SDA-5 校正済み | $\mathbf{0.4721 \pm 0.0099}$ | 100 |
| 直接 KV 検索（閾値未満はゼロ） | $0.4962 \pm 0.0101$ | 96 |

SDA-5 校正済みの MSE は KDA 型近似より 0.4615 低い。16 シードの対応のある差について、SDA の改善幅の Student の $t$ 分布による 95% 区間は $[0.4384, 0.4845]$ である。ただし **SDA の容量は KDA の 25 倍**である。直接 KV 検索に対する SDA の改善幅は 0.0241（95% 区間 $[0.0217, 0.0265]$）で、4 KiB の高速状態を追加して得られた結果である。これらの区間は合成分布におけるシード間変動であり、自然言語タスクへの汎化を意味しない。

## 4.2 KV 保存率と精度

$N = 512$、ノイズなしの SDA 校正済み MSE は KV 保存率 10%、25%、50% でそれぞれ 0.8475、0.7098、0.4721 となり、全件保存ではほぼゼロである。KV 保存量を増やすことで検索精度は改善するが、メモリの増加を伴う。図3には SDA だけでなく、直接 KV 検索の性能も併記する。

## 4.3 Query ノイズと系列長

$N = 512$、保存率 50% で $\sigma = 1$ とすると、SDA 校正済み MSE は 0.8077、KDA 型近似は 0.9504 であった。一方、SDA の信頼度ゲート通過率は約 14.84% まで低下した。ノイズなしの $N = 2048$ では SDA の

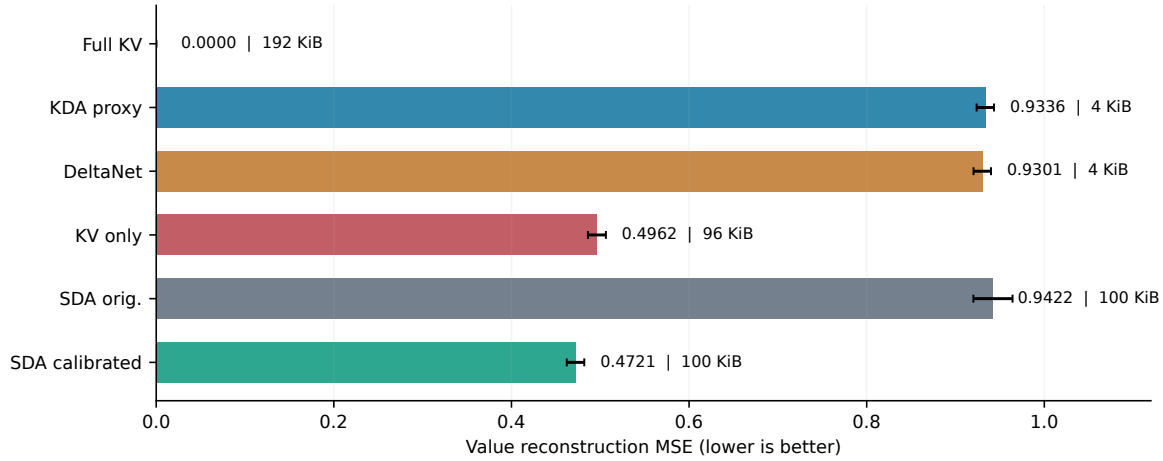



**Figure 2:** 主要な精度比較。各バーの右側に MSE と状態・KV 容量を表示した。同容量比較ではない点に注意。

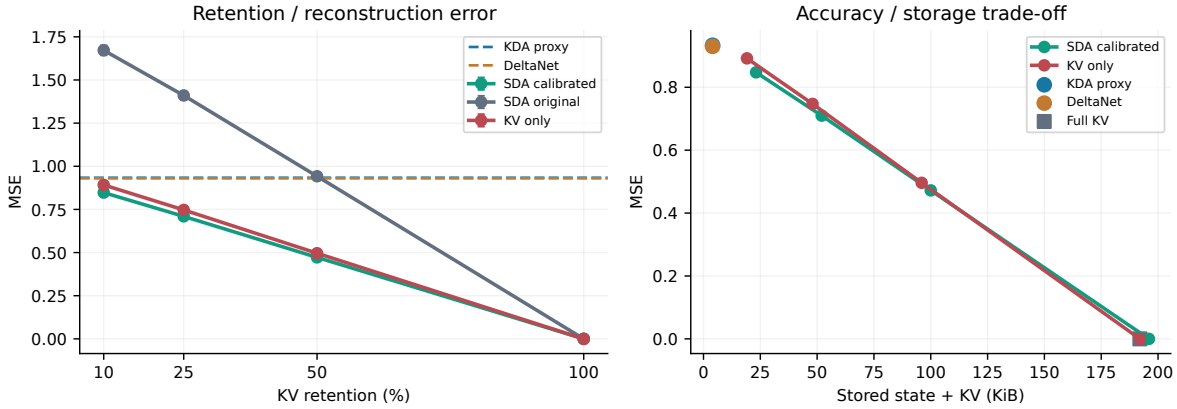



**Figure 3:** 左：KV 保存率と MSE。右：理論記憶容量と MSE の関係。固定サイズの KDA 状態は 4 KiB である。インデックスや一時配列の容量は含まない。

MSE は 0.5207、容量 388 KiB、KDA 型近似は MSE 1.0105、容量 4 KiB であった。ハイパーパラメータは $N = 512$ で選んだ値をそのまま使用しており、系列長ごとに再最適化していない。

# 5 考察と限界

**記憶容量の不一致：** KDA 型再帰更新は固定状態のみを持つ。一方、SDA は元 Value を部分保存するため、一致した Key から正確に再現できる。SDA の低 MSE はこの容量差に依存しており、Delta 更新則自体が KDA より優れることを示さない。

**実 KDA との相違：**比較対象は論文の再帰式を用いた未学習のゲート近似であり、訓練済み Kimi Linear の評価ではない。最良ゲートがほぼ忘却なしとなったことは、値が変化しないランダム対応を学ぶ本課題の性質による可能性があり、言語モデルでのチャネル別忘却の価値を否定しない。KDA の入力依存ゲートや射影を学習した公平な比較は未実施である。

**実験の限界：**すべての書き込み後の検索を評価しており、逐次的な因果 LM 評価ではない。自然言語・連続した文脈、意図的な Key 衝突、同一 Key の Value 変更、パラメータ学習、GPU の速度・ピークメモリ、ANN 検索は評価していない。Full Attention は Logit 倍率 32 を利用しており、対等な速度やモデル性能の比較にはならない。開発用の閾値は 50% 保存で選ばれており、他の予算での最適性を保証しない。

**新規性：** SDA の残差補正は、式(10)から直接 KV 検索と再帰状態の組合せに書き換えられる。外部 KV 検索には既存研究 [6] があり、KDA、Gated DeltaNet-2、Titans などにも異なる記憶制御方式がある [4, 5, 7]。独自性を立証するには、同一ピークメモリの学習済み比較や、干渉と検索誤差に関する新たな保証が必要である。

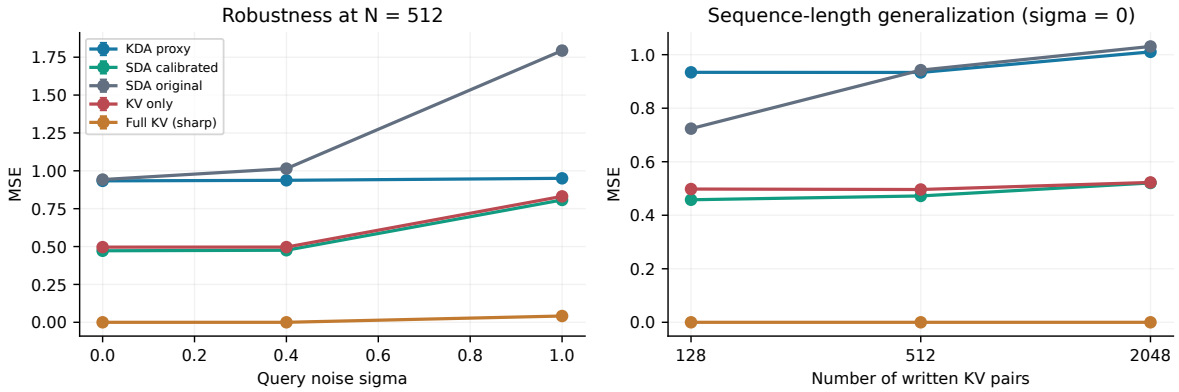



**Figure 4:** 左：ノイズ耐性。右：系列長を 128、512、2,048 に変えた場合の再現精度。グラフのモデル名は英語実装名である。

## 6 結論

本合成実験では、校正済み SDA-5 は KDA 型の未学習再帰モデルより低い Value 再現誤差を示した。しかし、25 倍の状態・KV 容量を使用するため、KDA に対する性能優位を一般化することはできない。次段階では、実際の学習済み KDA を含む同一パラメータ数・同一 FLOPs・同一ピークメモリでの比較、Causal な逐次評価、長文検索と Perplexity、GPU 実測、保存対象選別と ANN 管理領域の評価が必要である。

## A 再現方法

添付の `experiment.py` は `configuration.json`、`raw_results.csv`、`summary_results.csv` を出力する。`figures.py` は図を生成する。`OPENBLAS_NUM_THREADS=1 python experiment.py` の後に `python figures.py` を実行する。計算は float64、乱数は NumPy の `default_rng` を使用した。試行ごとに同じ Key、Value、Query、保存対象を各方式へ渡し、テスト 16 シードは設定選択に使わない。KDA 更新は忘却後の状態から誤差を計算し、Rank-1 の Delta 修正を加える厳密な再帰実装である。ただしゲートは本稿独自の非学習近似である。

## References

[1] Vaswani, A. et al. (2017). Attention Is All You Need. NeurIPS. https://arxiv.org/abs/1706.03762.
[2] Schlag, I., Irie, K., Schmidhuber, J. (2021). Linear Transformers Are Secretly Fast Weight Programmers. ICML. https://proceedings.mlr.press/v139/schlag21a.html.
[3] Yang, S., Kautz, J., Hatamizadeh, A. (2025). Gated Delta Networks: Improving Mamba2 with Delta Rule. ICLR. https://arxiv.org/abs/2412.06464.
[4] Kimi Team et al. (2025). Kimi Linear: An Expressive, Efficient Attention Architecture. arXiv:2510.26692. https://arxiv.org/abs/2510.26692.
[5] Hatamizadeh, A., Choi, Y., Kautz, J. (2026). Gated DeltaNet-2: Decoupling Erase and Write in Linear Attention. arXiv:2605.22791. https://arxiv.org/abs/2605.22791.
[6] Wu, Y., Rabe, M. N., Hutchins, D., Szegedy, C. (2022). Memorizing Transformers. ICLR. https://arxiv.org/abs/2203.08913.
[7] Behrouz, A., Zhong, P., Mirrokni, V. (2025). Titans: Learning to Memorize at Test Time. https://arxiv.org/abs/2501.00663.